




HOCH
SCHULE
OFFEN
BURG

Campus Next-Gen Data-Hub


Informatik Master Projekt SoSe 2026

Prof. Dr. Max Mustermann | 31.08.2023

Ist - Stand Datensynchronisation Campus IT



Ziel Architektur



Welche Tools kommen in Frage ?



- Apache Hop <https://hop.apache.org/>
- Pentaho <https://community.hitachivantara.com/s/article/downloads>
- Apache Nifi <https://nifi.apache.org/>
- Airbyte <https://airbyte.com/>

Was muss das System können?



- Abfragen von SOAP und Rest API Schnittstellen
- Logging und Monitoring von Jobs/Task/...
- Datei basierte Daten (csv, Excel, json, xml) einlesen
- diverse DB Anbindungen bereitstellen (min. Informix, MySQL, PostgreSQL)
- Daten Mapping und Transformation über eigene Code / Routinen / o.ä.
- Low-Code Rest API für Datenzugriffe ermöglichen
- Steuerung/Ausführung von eigenen Code-Snippets für komplexe Szenarien (like Selenium ??)

- eingesetztes Tool sollte open source sein und eine aktive Community (support + weiterentwicklung)
- Tests und evaluierung der Möglichkeiten der entsprechenden Szenarien
- Usability einfache Konfiguration
- Gut in Hochschul IT Systemlandschaft integrierbar

zu Testen -> siehe Szenarien (später)



- SOAP Requests bündeln in DB (h1)
- PostgreSQL in MySQL dumpen
- Spezifische Tabellen in eine andere DB
- Excel Dateien in eine MySQL DB
- komplexe ETL-Transformationen / Mapping
- xml und json mapping/transformation
- Anbindung als REST API
- Ausführen von eigenen Code Snippets (python, javascript und/oder Groovy)

- Evaluierung der möglichen Umsetzung von Testszenarien
- Aufbau einer Systemumgebung für Evaluation/Tests (Dockercontainer ?)
- Dokumentation der Tools und der Architektur des Projektes

Anforderungen an das System



Verschiedene Datenquellen/Ziele

- MySQL
- informix
- SOAP
- csv (teilweise Versand per Mail)
- MS Excel (muss teilweise von anderen orte abgeholt werden)
- textfile (für Logs & Versand per Mail)

Exportierbarkeit

Wartbarkeit

Skalierbarkeit

Datenhandling

- filtern
- ändern (trim, replace, regex, if/else,...)
- mappen
- zuordnen (FK)
- vereinigen

Logging

- Fehler bei Datentransfers
- Bestätigung von Aktionen

Wie es momentan Läuft



Exportierung

- Jobs können ohne weitere Probleme auf anderen Maschinen ausgeführt werden (bsp: Verwaltung kann ein Skript zum Anlegen von Studenten nutzen)

Logging und Scheduling

- Talend generiert einzelne Jobs
- custom Skripte für Job Ausführung und Logging
- Aufgabenplanung stößt Skripte an

→ d.h. Wenn die Jobs exportierbar sind, könnten sie auch via der bisherigen Strukturen ausgeführt werden, sofern die Anwendung kein self scheduling zulässt.

Wartung

- einfaches editieren von Jobs, mappings und Tabellenschemas
- pausieren von Jobs bei Wartungsarbeiten an Datenquellservern



HOCH
SCHULE
OFFEN
BURG